

1. Výkon modelu (mAP) na testovací sadě

Model dosáhl na testovací sadě celkového mAP@50 ve výši 0,893 (89,3 %). Detailní výsledky pro jednotlivé třídy jsou následující:

Třída	mAP@50	mAP@50:95	Precision (Přesnost)	Recall (Úplnost)
Žárovka (lightbulb)	0,943	0,921	0,977	0,780
Mušle (sea_shell)	0,844	0,793	0,751	0,780
CELKEM (průměr)	0,894	0,857	0,864	0,780

2. Vizuální test a dokumentace výsledků

Vizuální testování potvrdilo vysokou spolehlivost modelu při detekci organických i průmyslových objektů.

- Úspěšné detekce: Model vykazuje mimořádnou přesnost zejména v lokalizaci žárovek a je vysoce odolný vůči falešným detekcím.
- Chyby modelu (Neúspěšné detekce): K přehlédnutí objektů (nižší Recall) dochází v případech extrémního překryvu nebo když textura mušle splývá s podkladem.

3. Technická zpráva (Shrnutí procesu a kritické zhodnocení)

Celý proces vývoje zahrnoval čtyři klíčové fáze:

1. Akvizice a čištění dat: Původní dataset 12 000 snímků byl redukován pomocí Laplacianova operátoru, který odfiltroval neostré snímky.
2. Anotace: Byl využit poloautomatický proces v nástroji CVAT, kombinující manuální základ (254 snímků), automatické před-označení pomocným modelem a finální lidskou verifikaci.
3. Trénování: Proběhlo v prostředí MetaCentrum na GPU NVIDIA A100 s využitím architektury RF-DETR a backbonu DINoV2. Pro nasazení byla nutná manuální re-inicializace klasifikačních vrstev z 91 na 3 třídy.
4. Evaluace: Model byl úspěšně validován na datech, která nikdy neviděl (Test set 10 %).

Kritické zhodnocení a návrhy na zlepšení:

- Analýza chyb: Mírně nižší hodnota Recall (0,78) u obou tříd značí prostor pro zlepšení v detekci hůře viditelných objektů.
- Návrhy na zlepšení:
 - Rozšíření datasetu o augmentace simulující různé světelné podmínky (např. Random Brightness) pro zvýšení Recall.
 - Export modelu do formátů TensorRT nebo ONNX pro snížení latence při nasazení v reálném čase.
 - Implementace metody Tiling (SAHI) pro lepší detekci velmi malých objektů.









